

| Классическое машинное обучение

#Машинное_обучение/Единый_материал_по_классическому_МО/
Классическое_машинное_обучение

| Оглавление

| Предисловие

Данный материал я подготавливаю как справочный, поэтому расположение разделов не обязано соответствовать учебному формату.

Также мы сосредоточимся на классических методах машинного обучения (без нейросетей) в контексте табличных данных. Обработка текстов, изображений и аудио затрагиваться не будет.

| Введение

| Для чего нужно машинное обучение

В бизнесе да и просто в мире есть множество трудно формализуемых или вообще не формализуемых задач.

Под трудной формализацией понимается трудность придумать чёткий алгоритм решения. Например, есть задача по определению стоимости квартиры при её заданных параметрах. Параметров может быть очень много, все они могут влиять друг на друга и влиять на ответ комплексно, что делает построение решения, через `if else` не просто громоздким, но и практически не возможным. В таких случаях и требуется машинное обучение.

То есть машинное обучение применяется для решения сложных, трудно формализуемых задач, написание алгоритмов для которых в практическом плане либо слишком трудно, либо невозможно.

| Что понимается под машинным обучением

Всё машинное обучение работает с данными. И, если не вдаваться в подробности, то работает оно так: мы получаем данные о чём-либо, передаём их в модель машинного обучения, модель проводит с ними какие-то вычисления и на выход выдаёт ответ на наш вопрос. Данная конструкция очень напоминает математическую функцию:

$$f(X) = y$$

где X - данные, $f(X)$ - модель машинного обучения (функция), y - ответ, который дала модель.

Как известно, у каждой функции есть свои внутренние элементы - параметры, посредством которых она и взаимодействует с данными. Тогда суть машинного обучения заключается в настройке этих параметров, чтобы функция выдавала точные ответы.

Терминология

x - объект (sample), который передаётся в модель. Такой объект характеризуется набором параметров $x = \{x_1, x_2, \dots, x_n\}$ (n - количество признаков). Если для объекта мы знаем ответ (какой-то признак или значение, которое мы хотим предсказать/вычислить), то он обозначается y (target). Совокупность объектов для задачи называется пространством объектов - X , а совокупность ответов - пространством ответов Y . Если же объединить объекты и ответы, то получится обучающая выборка $\{(x_i, y_i)\}_{i=1}^l$, где l - размер обучающей выборки (В общем случае в обучающей выборке не обязательно должны быть ответы, так как например для задачи кластеризации их нет).

Таким образом получаем следующее:

1. $x = \{x_1, \dots, x_n\}$ - объект;
2. X - пространство объектов;
3. y - предсказываемый признак (ответ);
4. Y - пространство ответов;
5. $\{(x_i, y_i)\}_{i=1}^l$ - обучающая выборка.

Виды признаков и виды машинного обучения

Виды признаков

Признаки, характеризующие объекты, могут быть разных видов:

1. Числовые $x_i \in R$;
Примеры: высота, ширина, дальность полёта.
2. Категориальные $x_i \in \{C_1, \dots, C_m\}$, где C_i - какая-то категория;
Примеры: здоров или не здоров, виды пингвинов.
3. Порядковые $x_i \in \{C_1, \dots, C_m : C_i < C_j \ \forall i < j\}$
Примеры: курс, группа крови.

Это базовые тип признаков. Конечно же разные типы признаков нужно обрабатывать по разному, о чём будет написано в соответствующей главе.

Виды машинного обучения

От типа решаемой задачи и типа предсказываемого признака и формируются виды машинного обучения. Рассмотрим их ниже:

Обучение с учителем (supervised learning)

Данный тип обучения является одним из трёх глобальных видов обучения.

Характеризуется он в первую очередь тем, что для каждого набора признаков (объекта) нам известен верный ответ, который присутствует в обучающей выборке.

В зависимости уже от типа предсказываемой переменной обучение с учителем делится на подтипы:

1. Регрессия

В данном подтипе в качестве целевого признака выступает непрерывное число $Y \subseteq R$, например сумма кредита, которую можно доверить клиенту.

2. Классификация

В данном случае мы предсказываем класс объекта из конечного множества. А уже от природы классов зависят типы классификации:

1. Бинарная классификация $y \in \{-1, +1\}$;
2. Многоклассовая классификация $y \in \{1, 2, \dots, K\}$;
3. Классификация с пересекающимися классами $y \in \{0, 1\}^K$

Скорее всего это не все типы, но как минимум основные.

Обучение без учителя (unsupervised learning):

Данный тип задач характеризуется тем, что в обучающей выборке отсутствует целевая переменная. Например, у нас есть различные пользователи социальной сети и мы хотим разделить их на группы для рекомендаций им тематических сообществ, но какие конкретно им группы присвоить мы не знаем и знать не можем.

Задачи обучения без учителя:

1. Кластеризация;
2. Уменьшение размерности;
3. Оценивание плотности.

Обучение с подкреплением

Мне трудно тут что-то сказать, поэтому просто обозначу, что такой тип есть и при помощи него обучают автопилоты.

Итог по разделу

За раздел мы повторили, что называется машинным обучением и зачем оно нужно, ввели некоторую терминологию и разобрали типы признаков и вида задач.

В следующем разделе речь пойдёт о данных и работе с ними.